

Universidade do Minho

Escola de Engenharia Licenciatura em Engenharia Informática

Processamento de Linguagens

Ano Letivo de 2024/2025 Grupo 46

Gonçalo Gonçalves (a100833) Diogo Fernandes (a100746) Samuel Ferreira (a100654)

1 de junho de 2025

Índice

1	Intro	odução				
2	Arquitetura do Sistema					
	2.1	Visão Geral da Arquitetura				
	2.2	Fluxo de Processamento				
	2.3	Estrutura de Dados Principal - AST				
		2.3.1 Nós de Estrutura do Programa				
		2.3.2 Nós de Controle de Fluxo				
		2.3.3 Nós de Operações				
		2.3.4 Nós de Dados e Acesso				
		2.3.5 Nós de I/O				
		2.3.6 Tratamento de Erros				
	2.4	Sistema de Geração de Código				
		2.4.1 Mapeamento de Variáveis				
		2.4.2 Gestão de Variáveis				
		2.4.3 Geração de Labels				
		2.4.4 Instruções Assembly Geradas				
3	Análise Léxica (LEX)					
	3.1	Fundamentos da Análise Léxica				
	3.2	Implementação do Lexer				
		3.2.1 Palavras Reservadas				
		3.2.2 Definição de Tokens				
		3.2.3 Expressões Regulares				
		3.2.4 Operadores e Atribuição				
	3.3	Tratamento de Comentários				
	3.4	Gestão de Erros Léxicos				
	3.5	Características Avançadas do Lexer				
		3.5.1 Símbolos Literais				
		3.5.2 Controle de Linha				
	3.6	Criação do Lexer				
4	Δnál	lise Sintática (YACC)				
•	4.1	Fundamentos da Análise Sintática	•			
	4.2	Precedência de Operadores				
	4.2	Estrutura da Gramática				
	4.5	4.3.1 Programas Pascal				
		4.3.2 Declarações				
		4.3.2 Declarações				
	4 4	4.3.4 Subprogramas				
	4.4	Bloco Principal				

	4.5	Comandos e Estruturas de Controle	12
		4.5.1 Comando Composto	12
		4.5.2 Atribuições	12
		4.5.3 Condicional if	12
		4.5.4 Laços for e while	12
	4.6	Expressões	13
		4.6.1 Expressões Booleanas e Aritméticas	13
		4.6.2 Termos e Fatores	13
	4.7	Entrada e Saída	13
	4.8	Chamadas de Funções e Procedimentos	13
	4.9	Tratamento de Erros Sintáticos	14
	4.10	Construção da AST	14
	4.11	Validações Semânticas Simples	14
5	Inter	pretação e Execução 1	L 5
	5.1	Padrão Visitor	15
	5.2	Gestão de Variáveis	15
	5.3	Avaliação de Expressões	15
6	Conc	clusão 1	L 6
-	6.1		16
	6.2	' '	16
	6.3	'	- o 17
	U.S		
	6.4	, ,	17

1 Introdução

Este relatório apresenta uma análise técnica detalhada de um interpretador para a linguagem Pascal implementado em Python. O projeto constitui um sistema completo de análise e execução de código Pascal, desenvolvido utilizando as ferramenias PLY (Python Lex-Yacc), que fornecem funcionalidades equivalentes aos clássicos lex e yacc do ambiente Unix.

A implementação segue uma arquitetura modular bem estruturada, dividindo claramente as responsabilidades entre análise léxica, análise sintática e interpretação. O sistema é capaz de processar um subconjunto significativo da linguagem Pascal, incluindo declarações de variáveis, estruturas de controle, operações aritméticas e lógicas, e operações de entrada/saída.

O objetivo principal deste interpretador é demonstrar os conceitos fundamentais de construção de compiladores e interpretadores, proporcionando uma compreensão prática de como transformar código fonte em execução através das fases de tokenização, parsing e avaliação da árvore sintática abstrata (AST).

2 Arquitetura do Sistema

2.1 Visão Geral da Arquitetura

O compilador Pascal segue uma arquitetura em camadas típica de sistemas de processamento de linguagens, composta por quatro módulos principais:

- 1. Módulo de Análise Léxica (pascal_lex.py) Responsável pela tokenização
- Módulo de Análise Sintática (pascal_parser.py) Responsável pelo parsing e construção da AST
- 3. **Módulo de Nós AST** (ast_nodes.py) Define a estrutura da árvore sintática abstrata e geração de código
- Módulo de Geração de Código (integrado em ast_nodes.py) Transforma a AST em código assembly

2.2 Fluxo de Processamento

O processamento do código Pascal segue um pipeline bem definido:

```
Código Pascal 	o Tokenização 	o Parsing 	o AST 	o Geração de Código 	o Assembly
```

- 1. **Tokenização**: O código fonte é decomposto em tokens (palavras-chave, identificadores, operadores, etc.)
- 2. **Análise Sintática**: Os tokens são organizados em uma estrutura hierárquica (AST) seguindo a gramática Pascal
- 3. Mapeamento de Variáveis: As variáveis são mapeadas para posições de memória global
- 4. **Geração de Código**: A AST é percorrida e transformada em código assembly através do método generate_code()

2.3 Estrutura de Dados Principal - AST

A árvore sintática abstrata é implementada através de uma hierarquia de classes que herdam de ASTNode. Cada tipo de construção Pascal tem sua representação correspondente. É de notar que, diferentemente das demais classes de nós, o nodo IndexNode **não herda** de ASTNode.

Classes para Acesso por Índice

Existem duas classes distintas para manipulação de índices:

- IndexNode: Utilizada para acesso a arrays em operações de leitura e escrita.
- IndexAccessNode: Utilizada para acesso de caracteres em strings (com operação charat).

2.3.1 Nós de Estrutura do Programa

- ProgramNode: Representa o programa principal, gera código com start e stop
- CompoundNode: Agrupa comandos em blocos
- FunctionDeclNode: Declarações de funções com parâmetros e variáveis locais
- ProcedureDeclNode: Declarações de procedimentos

De modo a garantir um estado limpo para cada compilação, a função ProgramNode.generate_code() reinicializa as estruturas globais de mapeamento de variáveis (var_positions, next_var_index) no início de sua execução. Isto evita que definições de variáveis de uma compilação anterior afetem a compilação atual.

2.3.2 Nós de Controle de Fluxo

• IfNode, WhileNode, ForNode: Estruturas de controle com geração de labels para saltos

O construtor de BinaryOpNode verifica explicitamente se seus operandos são instâncias de ASTNode, lançando exceções detalhadas caso contrário. Isso permite detectar precocemente problemas de tipo na AST com mensagens como:

```
Exemplo de erro
[ERRO] Left operand não é ASTNode: {left} ({type(left).__name__})
```

2.3.3 Nós de Operações

AssignNode, BinaryOpNode, FuncCallNode

Funções Embutidas

Apesar do dicionário funcoes_embutidas conter apenas três entradas (length, ord, chr), o método FuncCallNode.generate_code() dá suporte completo às seguintes funções:

- Funções numéricas: abs, sqrt, round, trunc, sqr, succ, pred
- Conversão e manipulação de caracteres: ord, chr, upcase, lowercase
- Manipulação de strings: length, pos, copy, concat, insert, delete
- Conversão de tipos: val, str

2.3.4 Nós de Dados e Acesso

VarNode, IndexNode, NumberNode, StringNode, BooleanNode

Instrução de Debug Permanente

A função IndexNode.generate_code() contém uma instrução de depuração permanente no código:

```
print(">> DEBUG IndexNode: self.array =", self.array)
```

2.3.5 Nós de I/O

- WriteNode: Realiza escrita na saída padrão. Aplica heurística baseada no prefixo do nome da variável: se começar por "msg" ou "txt", assume que o conteúdo é uma string e utiliza writes.
- ReadNode: Sempre aplica conversão de string para inteiro usando atoi. Isso implica que apenas leitura de inteiros está atualmente suportada.

É de notar que, para arrays, o nodo ReadNode usa a sequência add+storen para armazenar no elemento indexado, enquanto que, para variáveis simples, usa storeg.

2.3.6 Tratamento de Erros

ErrorNode: Usado para sinalização e propagação de erros durante a análise sintática.

2.4 Sistema de Geração de Código

2.4.1 Mapeamento de Variáveis

mapear_variaveis(ast) é uma função fundamental para atribuir posições de memória a variáveis globais e locais. Ela percorre a AST e associa cada variável a um índice numérico único, armazenado em um dicionário global chamado var_positions. Esses índices são posteriormente utilizados durante a geração de código para instruções como pushg, storeg, etc.

2.4.2 Gestão de Variáveis

- var_positions: Dicionário que mapeia nomes de variáveis para índices únicos
- next_var_index: Contador global para atribuição de posições

Nas funções e procedimentos, o estado global (var_positions, next_var_index, declared_variables) é salvo antes da geração de código da função e restaurado depois, garantindo isolamento de escopos.

2.4.3 Geração de Labels

• gen_label(): Função auxiliar para geração de rótulos únicos

2.4.4 Instruções Assembly Geradas

O código gerado é direcionado a uma máquina virtual baseada em pilha:

• Stack: pushi, pushs, pushg, pop

Armazenamento: storeg

• Aritmética: add, sub, mul, div, mod

• Relacional: equal, inf, sup, infeq, supeq

• Lógica: and, or, not

■ Controle: jz, jump

■ I/O: writei, writes, writeln, read, atoi

• Subrotinas: pusha, call, return

3 Análise Léxica (LEX)

3.1 Fundamentos da Análise Léxica

A análise léxica constitui a primeira fase do processo de compilação/interpretação. No contexto deste projeto, o módulo pascal_lex.py implementa um analisador léxico utilizando a biblioteca PLY (Python Lex-Yacc), que fornece funcionalidades equivalentes ao lex tradicional.

O analisador léxico transforma a sequência de caracteres do código fonte em uma sequência de tokens, removendo espaços em branco e comentários, e classificando cada elemento léxico de acordo com sua categoria sintática.

3.2 Implementação do Lexer

3.2.1 Palayras Reservadas

O sistema define um conjunto abrangente de palavras reservadas da linguagem Pascal como tokens individuais:

```
def t_PROGRAM(t): r'program'; return t
2 def t_BEGIN(t):     r'begin';     return t
def t_END(t):
                  r'end';
                               return t
                r'var';
4 def t_VAR(t):
                              return t
return t
                              return t
8 def t_FUNCTION(t): r'function'; return t
9 def t_PROCEDURE(t): r'procedure'; return t
def t_WRITELN(t): r'writeln'; return t
11 def t_READLN(t): r'readln';
                               return t
return t
                               return t
                               return t
               r'div';
17 def t_DIV(t):
                               return t
                  r'mod';
18 def t_MOD(t):
                              return t
                  r'and';
19 def t_AND(t):
                              return t
                  r'or';
20 def t_OR(t):
21 def t_NOT(t):
                  r'not';
22 def t_TRUE(t):
                  r'true';
23 def t_FALSE(t):
                  r'false';
                               return t
24 def t_ARRAY(t): r'array'; return t
```

```
25 def t_OF(t): r'of'; return t
```

Figura 3.1: Definição de tokens para palavras reservadas

3.2.2 Definição de Tokens

A lista de tokens inclui identificadores, números, strings, operadores e tipos:

Figura 3.2: Lista de tokens

3.2.3 Expressões Regulares

Os padrões são definidos por expressões regulares:

```
def t_ID(t):
    r'[a-zA-Z_][a-zA-Z0-9_]*'
    return t

def t_NUMBER(t):
    r'\d+'
    t.value = int(t.value)
    return t

def t_STRING(t):
    r'\'([^\\\n]|(\\.))*?\''
    t.value = t.value[1:-1]
    return t
```

Figura 3.3: Expressões regulares para tokens

3.2.4 Operadores e Atribuição

Figura 3.4: Operadores de atribuição e comparação

3.3 Tratamento de Comentários

Dois tipos de comentários são reconhecidos e ignorados pelo lexer:

```
def t_COMMENT(t):
    r'\{[^}]*\}'
    pass

def t_COMMENT_LINE(t):
    r'//.*'
    pass
```

Figura 3.5: Comentários

3.4 Gestão de Erros Léxicos

Caracteres não reconhecidos são tratados por:

```
def t_error(t):
    print(f"Carácter ilegal '{t.value[0]}' na linha {t.lineno}")
    t.lexer.skip(1)
```

Figura 3.6: Tratamento de erros léxicos

3.5 Características Avançadas do Lexer

3.5.1 Símbolos Literais

Os literais são tratados diretamente:

```
1 literals = ['+', '-', '*', '/', ';', ',', ':', '(', ')', '[', ']', '.']
```

3.5.2 Controle de Linha

A função abaixo mantém a contagem de linhas atualizada:

```
def t_newline(t):
    r'\n+'
    t.lexer.lineno += len(t.value)
```

3.6 Criação do Lexer

Por fim, o objeto lexer é criado com:

```
import ply.lex as lex
lexer = lex.lex()
```

Figura 3.7: Construção do lexer

O modo re.IGNORECASE é ativado para tornar a análise insensível a maiúsculas e minúsculas, refletindo o comportamento da linguagem Pascal.

4 Análise Sintática (YACC)

4.1 Fundamentos da Análise Sintática

A análise sintática é a segunda fase do compilador e verifica se a sequência de tokens gerada pelo analisador léxico segue as regras gramaticais da linguagem Pascal. Nesta etapa, também é construída a árvore sintática abstrata (AST). O analisador sintático é implementado no módulo pascal_parser.py usando a técnica LALR(1) através da biblioteca PLY yacc.

4.2 Precedência de Operadores

A tabela de precedência resolve ambiguidades na interpretação de expressões:

Figura 4.1: Tabela de precedência

4.3 Estrutura da Gramática

4.3.1 Programas Pascal

A definição de programa em Pascal inicia com a palavra-chave PROGRAM, seguida pelo identificador, declarações, um bloco principal e um ponto final:

```
def p_programa(p):
    'programa : PROGRAM ID ";" declaracoes bloco_simples "."'
    globais, funcoes = p[4]
    ...
    p[0] = ProgramNode(p[2], funcoes, p[5])
```

Figura 4.2: Regra gramatical para programas

4.3.2 Declarações

As declarações podem conter variáveis, funções e procedimentos:

Figura 4.3: Combinação de declarações

4.3.3 Variáveis

A declaração de variáveis verifica se já foram declaradas e registra os nomes:

```
def p_decl(p):
    'decl : lista_ids ":" tipo ";"'
    ...
    p[0] = nomes
```

Figura 4.4: Declaração de variáveis

4.3.4 Subprogramas

Funções e procedimentos são declarados conforme mostrado:

```
def p_funcao(p):
    'funcao : FUNCTION ID "(" parametros ")" ":" tipo ";"
    declaracoes_variaveis_opt bloco_simples ";"'

def p_procedimento(p):
    'procedimento : PROCEDURE ID "(" parametros ")" ";"
    declaracoes_variaveis_opt bloco_simples ";"'
```

Figura 4.5: Funções e procedimentos

4.4 Bloco Principal

O bloco principal pode conter apenas comandos ou também declarações locais:

```
def p_bloco_simples(p):
    '''bloco_simples : BEGIN comandos END
    | BEGIN declarações_variaveis comandos END'''
```

Figura 4.6: Bloco simples

4.5 Comandos e Estruturas de Controle

4.5.1 Comando Composto

Agrupa uma sequência de comandos entre BEGIN e END:

Figura 4.7: Comando composto

4.5.2 Atribuições

Verifica a declaração da variável antes de gerar a atribuição:

```
def p_atribuicao(p):
| 'atribuicao : ID ASSIGN expressao'
```

Figura 4.8: Comando de atribuição

4.5.3 Condicional if

O uso de precedência resolve ambiguidades como o "dangling else":

Figura 4.9: Comando if-then-else

4.5.4 Laços for e while

Ambas as formas de for são suportadas:

Figura 4.10: Comando for

O laço while também é reconhecido:

```
def p_comando_while(p):
    'comando_while : WHILE expressao DO comando'
```

Figura 4.11: Comando while

4.6 Expressões

4.6.1 Expressões Booleanas e Aritméticas

A estrutura hierárquica garante a precedência correta:

Figura 4.12: Expressões binárias

4.6.2 Termos e Fatores

Os termos suportam operadores multiplicativos, lógicos e aritméticos:

```
def p_termo(p):
    '''termo : fator
    | termo '*' fator
    | termo DIV fator
    | termo MOD fator
    | termo AND fator'''
```

Figura 4.13: Operadores binários

4.7 Entrada e Saída

A linguagem reconhece comandos de entrada/saída como READLN e WRITELN:

Figura 4.14: Entrada e saída

4.8 Chamadas de Funções e Procedimentos

As chamadas são verificadas quanto à existência e número de argumentos:

Figura 4.15: Chamada de função ou procedimento

4.9 Tratamento de Erros Sintáticos

O parser recupera erros reportando tokens inesperados:

```
def p_error(p):
    if p:
        print(f"Erro de sintaxe na linha {p.lineno}: token inesperado '{p.value }'")
        parser.errok()
else:
        print("Erro de sintaxe no fim do input")
```

Figura 4.16: Função de erro

4.10 Construção da AST

Cada regra constrói nós da árvore sintática:

```
def p_atribuicao(p):
    'atribuicao: ID ASSIGN expressao'
    ...
    p[0] = AssignNode(var_node, expr_node)
```

Figura 4.17: Construção de AST

4.11 Validações Semânticas Simples

Além da análise sintática, são realizados testes semânticos básicos, como:

- Verificação de variáveis e funções já declaradas
- Verificação do número de argumentos em chamadas de subprogramas
- Atribuições inválidas

5 Interpretação e Execução

5.1 Padrão Visitor

O interpretador utiliza o padrão Visitor para percorrer e executar a AST. Cada tipo de nó tem um método de visita correspondente:

```
def run(self, node):
    method_name = 'visit_' + type(node).__name__
    visitor = getattr(self, method_name, self.generic_visit)
    return visitor(node)
```

Figura 5.1: Método principal de execução

5.2 Gestão de Variáveis

O interpretador mantém um dicionário simples para armazenar variáveis:

```
def visit_AssignNode(self, node):
   value = self.run(node.expr)
   self.vars[node.var.name] = value
```

Figura 5.2: Execução de atribuições

5.3 Avaliação de Expressões

A avaliação de operações binárias suporta operadores aritméticos, lógicos e relacionais:

```
def visit_BinaryOpNode(self, node):
    left = self.run(node.left)
    right = self.run(node.right) if node.right is not None else None
    op = node.op
    if op == '+': return left + right
    if op == '-': return left - right
    # ... outros operadores
```

Figura 5.3: Avaliação de operadores binários

6 Conclusão

O interpretador Pascal apresentado demonstra uma implementação sólida e bem estruturada dos conceitos fundamentais de construção de linguagens de programação. A utilização das ferramentas PLY (Python Lex-Yacc) proporciona uma base robusta para a implementação das fases de análise léxica e sintática, seguindo as melhores práticas estabelecidas pelas ferramentas clássicas lex e yacc.

6.1 Pontos Fortes da Implementação

A arquitetura modular adotada facilita a manutenção e extensão do sistema. A separação clara entre análise léxica, sintática e interpretação permite modificações independentes em cada componente. O uso do padrão Visitor para a interpretação proporciona flexibilidade para futuras extensões, como geração de código ou otimizações.

A implementação da análise léxica demonstra compreensão sólida dos conceitos de tokenização, incluindo tratamento adequado de palavras reservadas, comentários e diferentes tipos de literais. O suporte a expressões regulares complexas para reconhecimento de strings e a gestão apropriada de números de linha para reportagem de erros evidenciam atenção aos detalhes práticos.

Na análise sintática, a gramática implementada cobre um subconjunto significativo da linguagem Pascal, incluindo estruturas de controle essenciais, declarações de variáveis e operações. O tratamento da ambiguidade "dangling else" através de precedências demonstra compreensão de questões sintáticas complexas.

6.2 Áreas para Melhoramento

Embora funcional, o interpretador apresenta algumas limitações que poderiam ser endereçadas em futuras iterações. A gestão de escopo é simplificada, utilizando apenas um dicionário global para variáveis. Uma implementação mais completa incluiria pilhas de escopo para suportar adequadamente subprogramas e variáveis locais.

O tratamento de tipos é básico, sem verificação estática de tipos ou conversões automáticas. A implementação de um sistema de tipos mais robusto melhoraria significativamente a qualidade do interpretador. Adicionalmente, o suporte a arrays está definido na gramática mas não completamente implementado no interpretador.

6.3 Valor Educacional e Aplicações

Este projeto serve como excelente exemplo educacional para compreensão dos princípios de construção de compiladores e interpretadores. A progressão lógica desde a tokenização até a execução ilustra claramente como código fonte é transformado em computação executável.

O uso de Python como linguagem de implementação torna o código acessível para estudantes, enquanto as ferramentas PLY proporcionam uma ponte natural para conceitos mais avançados encontrados em ferramentas profissionais de desenvolvimento de compiladores.

6.4 Considerações Finais

A implementação apresentada constitui uma base sólida para um interpretador Pascal completo. Com as extensões apropriadas — incluindo melhor gestão de escopo, sistema de tipos robusto e implementação completa de subprogramas — este projeto poderia evoluir para um interpretador Pascal totalmente funcional.

O trabalho demonstra que é possível criar sistemas de processamento de linguagens eficazes utilizando ferramentas modernas, mantendo os princípios teóricos estabelecidos pela literatura clássica da área. Esta abordagem híbrida — teoria sólida implementada com ferramentas contemporâneas — representa uma metodologia valiosa para o ensino e desenvolvimento de sistemas de software na área de linguagens de programação.